

“以生命为核心”的意识理论与人工意识的可能性

李恒威

【摘要】本文旨在探讨基于当代神经科学和生物学视角的“以生命为核心”的意识理论及其对机器意识、AI意识和人工意识研究的影响。“以生命为核心”的意识理论突破了传统计算功能主义框架,主张意识并非抽象信息加工的副产品,而是生物体为更好、更灵活地维持内稳态(homeostasis)而演化出的高级生命调节机制。其核心论点是:感受(feeling)作为内稳态评估的主观呈现,是意识的最初形式,它赋予生物体以自我感(sense of self)并成为一切适应性行为的原生驱动力。基于此,本文对机器意识与人工意识进行区分。由于意识在本质上是一种生命现象,而根据罗伯特·罗森的“生命-复杂系统”理论,生命不是机器,其生机是图灵机不可计算的。因此,在基于传统计算架构的机器(或人工智能系统)上实现意识(即机器意识)在原则上是不可能的。然而,这并未完全否定人工意识的可能性。本文提出,若跳出经典计算范式,转向构建以实现内稳态为根本目标的人工生命系统(artificial life system),则有可能在此生命基础上涌现出真正的意识体验。因此,实现人工意识的可行路径不在于编写更复杂的算法,而在于仿生地建构具有生命本质特征的系统。

【关键词】以生命为核心;意识理论;内稳态;机器意识;人工意识;罗伯特·罗森

中图分类号:B15 文献标识码:A 文章编号:1000-7660(2026)01-0068-09

作者简介:李恒威,(杭州 430062)浙江大学哲学学院教授暨脑机智能全国重点实验室兼聘研究员。

基金项目:国家社会科学基金重大项目“马克思主义认识论与认知科学范式的相关性研究”(22&ZD034);科技部科技创新2030-“脑科学与类脑研究”重大项目(2021ZD0200409)

一、引言

自人类踏上哲学与科学探索之路以来,意识之谜便始终占据着人类理解自身及与世界关系的关键位置。在认知科学与人工智能领域,关于意识的本质及其实现路径,长久以来被“计算功能主义”(computational functionalism)所主导。^①该范式将心智类比为软件,认为意识是信息处理达到特定复杂程度后涌现的功能属性,其载体可以是脑组织,也可以是硅基系统或其他介质系统。这种“强人工智能”的愿景催生了机器意识(machine consciousness)的目标,即通过算法和编程在非生命机器系统中再现意识。然而,数十年过去,尽管我们在特定任务上创造了甚至超越人类智能的机器,但那种内在、主观、富有感受的意识体验,却依然严格局限于生命有机体之内,从未在任何介质的机器系统中真正“觉醒”。

这一现实差异促使学界不断反思。多年来,一场如今可称为“生命转向”(life-turn)的变革,一直在意识研究的神经科学、生物学与哲学交汇处悄然且持续地涌动和深化。以瓦雷拉(Francisco Varela)等人的生成

^① 参见[美]科赫:《生命本身的感觉》,李恒威译,长沙:湖南科学技术出版社,2024年。

论(enactivism)^①、雅克·潘克赛普(Jaak Panksepp)的情感神经科学^②、迈克尔·加扎尼加(Michael S. Gazzaniga)的模块-层级理论^③、安东尼奥·达马西奥(Antonio Damasio)的意识内稳态调节理论^④、以及比约恩·默克尔(Bjorn Merker)^⑤和马克·索姆斯(Mark Solms)^⑥对意识皮层下起源的强调为代表,一批学者正从根本上挑战意识的计算功能主义框架。他们突破并摒弃纯粹的心智计算模型,将目光重新投向意识的生物学根基,共同倡导一种“以生命为核心”的(life-centered)意识研究。该进路主张:意识的起源、本质和功能必须从生命体维持存续、保障安康、实现适应的生物学目的论视角来理解,不可被简化为与生命无关的抽象信息加工。“以生命为核心”的意识理论持有一个强主张:意识是生命的专有属性,非生命系统不可能拥有意识。这一研究转向要求我们对机器意识(包括AI意识)与人工意识(artificial consciousness)这两个概念进行区分。它们虽然常被混淆,但有着不同的内涵,前者探讨机器(尤其是基于图灵机的机器或计算系统)是否能够具备意识,后者则探讨是否可以通过人工手段构建出具有意识的系统,且其载体未必局限于传统意义上的机器。

基于“以生命为核心”的意识理论,并结合罗伯特·罗森(Robert Rosen)关于生命系统与机器存在本质区别的“生命-复杂系统”理论,本文将从两个层次展开论证。首先,生命与机器有着本质上的不同,它无法被以图灵机为模型的计算系统完全模拟,因此作为生命现象的意识同样无法被计算模拟。这意味着,在传统的计算范式下,想通过机器或AI系统实现意识(即机器意识或AI意识)是不可能的。其次,本文将探讨一种更具前景的可能性:如果我们超越传统的机器范式,致力于通过工程化手段构建或仿生真正的人工生命系统,即能够自主维持内稳态并具有生物学意义的生命实体,那么在此基础上实现人工意识便具备了理论上的可能性。为此,本文会简要阐释“以生命为核心”的意识理论,并据此对机器意识、AI意识以及人工意识的可能性展开批判性审视。本文主张,通往人工意识的道路并非编写更复杂的代码,而在于理解生命的深层原理,并构建再现该原理的人工系统。这并非对强人工智能梦想的简单否定,而是旨在指明一条更契合意识生物学本质的方向。

二、意识研究的“生命转向”与意识的情感神经科学

意识研究的“生命转向”秉持的核心观点是:意识乃生物体为维系内稳态这一根本生命原则而演化出的高级调节机制。在此框架下,“以生命为核心”的意识理论提出三重核心主张:一是感受(如疼痛感或愉悦感)是意识最原始且最基本的形式;二是感受赋予生物体最原初的自我感;三是感受源于神经系统对内稳态状况的实时映射和评估,它是内稳态生理状况的主观呈现,并成为驱动所有适应性认知与行为的情感效价(affective valence)或内在动力。这里着重阐述潘克赛普对推动意识研究“生命转向”的开创性贡献。^⑦

潘克赛普作为情感神经科学的重要奠基人,其研究为“以生命为核心”的意识理论提供了坚实的实证和理论基础。通过数十年对哺乳动物(从啮齿类到灵长类)进行神经解剖学、脑区电刺激、神经化学操控及行为观察实验,潘克赛普突破了传统意识研究聚焦于新皮层认知功能的局限,将意识的起源与本质重新锚定

① 参见[智]瓦雷拉、[加]汤普森、[美]罗施:《具身心智:认知科学和人类经验》,李恒威、李恒熙等译,杭州:浙江大学出版社,2010年。

② 参见[美]潘克赛普、[英]彼文:《心智考古学:人类情绪的神经演化起源》,王昊晨、李恒威译,杭州:浙江大学出版社,2023年。

③ See Michael S. Gazzaniga, *The Consciousness Instinct: Unraveling the Mystery of How the Brain Makes the Mind*, Farrar: Straus and Giroux, 2018.

④ See Antonio Damasio, *The Feeling of What Happens: Body and Emotion in the Making of Consciousness*, New York: Harcourt Brace & Company, 1999.

⑤ See Bjorn Merker, “Consciousness without a Cerebral Cortex: A Challenge for Neuroscience and Medicine”, *Behavioral and Brain Sciences* 30 (1), 2007, pp. 63–81.

⑥ See Mark Solms, *The Hidden Spring: A Journey to the Source of Consciousness*, New York: W. W. Norton & Company, 2021.

⑦ 关于推动意识研究“生命转向”的加扎尼加、达马西奥、索姆斯等人的思想和贡献的阐述,参见李恒威、阮泽楠:《作为人工智能下一个关口的意识研究——从加扎尼加的意识学说切入》,《社会科学战线》2024年第3期;李恒威、曹旭婷:《机器如何可能有情感——基于“以生命为核心”的意识理论的探讨》,《科学·经济·社会》2025年第3期。

于生命存续的生物学根基。他明确提出:情绪和情感(affect)并非高阶认知的衍生物,而是在演化早期便已出现且植根于皮层下结构(如丘脑、脑干等)的原始意识形式,其功能直接服务于生物体的生存、适应与繁衍,是一种生命维系内稳态的新调节机制。“情感为生存提供了一种灵活的指导。在情绪演化之前,动物必须以更刻板僵化的方式行动。例如,原始海洋生物在穿越海洋时,除了匀速波动外别无选择。相对僵化的活动同样可以非常复杂——蜜蜂展现出多种本能功能,其中有些我们认为包含有情感内容。例如,研究显示,当蜜蜂从高浓度、高甜度的糖液转移到低浓度、不受欢迎的糖液时,它们的味觉神经元反应减弱,这可能与蜜蜂表现出的类似沮丧的行为反应有关。然而,哺乳动物成熟的情感能力使它们能够以高度灵活的方式应对当下的生活挑战。”^①

(一)情感的演化起源:皮层下的“祖传心智”

“就我们目前所知,由神经解剖学和神经化学揭示的原始情绪系统在所有哺乳动物中都十分相似。这意味着这些系统很久以前就已经演化了,并且在基本情绪和动机层面上,所有哺乳动物都更相似而非相异。”^②潘克赛普的实证研究表明,情绪系统是生物演化早期便已形成的“祖传心智”(ancestral mind),其神经基础集中于皮层下结构(包括丘脑、下丘脑、脑干导水管周围灰质及杏仁核内侧核等),而非演化后期出现的新皮层。这一发现从根本上挑战了将意识视为新皮层高级认知功能的主流观点,为“以生命为核心”的意识理论提供了关键实证支撑。

两类实验有力印证了这一观点。其一,对大鼠、猫等动物的皮层下脑区(如下丘脑腹内侧区、中脑导水管周围灰质)进行局部电刺激或化学刺激,可直接诱发稳定的情绪行为与生理反应。例如,刺激大鼠中脑导水管周围灰质特定区域,会引发其撕咬、咆哮、毛发直立的“愤怒攻击”行为,且该反应不依赖新皮层的完整性。其二,“去皮层动物”(即通过手术移除新皮层的实验动物)仍能表现出完整的情绪反应,如恐惧时僵住、愤怒时攻击、愉悦时主动探索,且能通过学习趋近带来愉悦的刺激、回避引发痛苦的刺激。这些实验表明,情绪体验的生成无需新皮层参与,而是由皮层下古老神经网络自主完成。^③

这种演化上的“古老性”深刻揭示了情绪与生命存续的内在联系:在复杂认知功能出现之前,情绪系统已成为生物体应对环境威胁(如捕食者、创伤)与机遇(如食物、配偶)的核心调节机制。作为生命为维持存续而演化出的“基础工具”,情绪系统直接服务于生物体的生存、适应与繁衍,而非作为新皮层认知功能的副产品。正如潘克赛普所言,皮层下系统是情绪研究的“考古学的宝藏”,它们不仅“包含了一些我们最强烈感受的来源”,而且构成所有基本价值的根基,是“生命中美与丑”的构建基础。^④这一发现不仅验证了情绪系统在演化过程中的优先地位,更突显了意识的生物学本质——意识并非抽象信息处理的结果,而是生命体为维持内稳态而演化出的高级调节机制。

(二)基本情绪系统:跨物种的生命调节模块

潘克赛普基于对动物情绪行为与脑区活动的关联分析,提出了“基本情绪系统”(basic emotional systems)理论。该理论将哺乳动物的基本情绪系统划分为七种具有跨物种保守性的类型,包括探索(seeking)、恐惧(fear)、愤怒(rage)、关怀(care)、惊慌/悲痛(panic/grief)、欲望(lust)和嬉戏(play)。这些系统并非对外部刺激的被动反应,而是自带内在动机的生命调节模块,其核心功能是通过监测内稳态参数(如血糖、体温、激素水平、社交联结状态),将生理需求转化为可体验的情绪感受,驱动适应性行为。例如,情绪监测系统通过获取目标测试人群的情绪状态监测数据,对数据进行预处理和特征选择,构建训练集,并基于特定算法构建

① [美]潘克赛普、[英]彼文:《心智考古学:人类情绪的神经演化起源》,第44页。

② 同上,第4页。

③ J. Panksepp, "The Basic Emotional Circuits of Mammals: A Neurobiological Perspective", *Neuroscience & Biobehavioral Reviews* 16 (1), 1992, pp.1-14.

④ J. Panksepp, *Minds in the Making: The Evolutionary Origins of Human Emotions*, Oxford: Oxford University Press, 1998.

情绪状态监测识别模型,从而准确监测和识别情绪状态。^①

以探索系统为例,其神经基础以腹侧被盖区(VTA)-伏隔核的多巴胺通路为核心。当生物体处于内稳态失衡(饥饿、口渴)或感知到潜在资源(食物气味、配偶信号)时,该系统被激活,多巴胺的释放会引发渴望、期待等积极情感,驱动动物主动探索环境、获取资源。实验中,大鼠会为获得该系统的电刺激持续按压杠杆,甚至忽略食物与水。这种自我刺激行为表明,探索系统所引发的情绪感受本身就是一种“生命奖赏”,它直接驱动生物体主动维持内稳态。^②

又如关怀系统,以催产素、催乳素为核心神经化学物质,激活后会促使动物表现出抚育幼崽的行为(筑巢、舔舐、护崽),并伴随温柔、满足等情绪感受。这一系统直接服务于物种的繁衍,体现了生命在意识层面上的“延续性”需求。潘克赛普强调,这些基本情绪系统在所有哺乳动物中具有高度相似的神经解剖和化学基础——人类母亲抚育婴儿时的脑区激活模式(下丘脑-杏仁核通路)与母鼠护崽时的模式高度重合。这印证了情绪系统是生命为“生存与繁衍”而演化出的基本的内稳态调节机制。^③

(三)情绪的功能:适应性行为的源生驱动力

情绪系统通过双路径机制驱动适应性行为,构成了维持生命内稳态的“双引擎”。其一为直接驱动:情感感受本身具备动机属性,正向情感(如探索系统的渴望、关怀系统的温柔)驱动动物主动趋近有益刺激,负向情感(如恐惧系统的惊惶、惊慌/悲伤系统的悲痛)驱动动物主动回避有害刺激。例如,当饥饿大鼠的探索系统被激活后,渴望情绪会促使其持续探索环境、挖掘食物,直至内稳态(血糖水平)恢复平衡。其二为学习强化:情绪体验作为奖赏/惩罚信号,会强化生物体对刺激-行为关联的学习。当大鼠在探索中偶然发现食物时,探索系统释放的多巴胺引发愉悦感受,这种感受能强化探索行为-获得食物的关联,使其未来更倾向通过探索获取资源;反之,如果大鼠在探索过程中遭遇电击(激活恐惧系统并引发痛苦),则会抑制其类似的探索行为。

值得注意的是,潘克赛普通过成瘾研究进一步验证情绪的驱动机制:可卡因、吗啡等成瘾药物通过劫持情绪系统(如提升多巴胺水平激活探索系统、模拟内源性阿片肽抑制惊慌/悲伤系统),制造强烈正向情感或缓解负向情感,从而驱动强迫性药物探索行为。这从反面印证情绪系统是调控生物趋利避害行为的核心中枢。

(四)感受:内稳态的“现象学转译”与意识的起点

潘克赛普的研究为“以生命为核心”的意识理论中“感受是内稳态评估的主观呈现”提供了实证依据。他通过神经化学操控实验揭示:感受是神经系统将内稳态生理参数(如组织损伤、血糖浓度、社交隔离)转化为“情感效价”(愉悦或痛苦)的主观体验,其本质是生命体对自身内稳态的第一人称监测。

这种自然发生的“现象学转译”^④通过两类神经机制实现。其一,内感受器-皮层下通路即身体器官的内感受器实时追踪生理状态(如炎症引发的组织损伤、脱水导致的血液渗透压变化),将信号传递至下丘脑、脑干等皮层下中枢;这些中枢通过释放神经肽(如阿片肽、P物质),将生理信号转译为情绪体验。例如,组织损伤会激活脊髓-脑干疼痛通路,促使中脑导水管周围灰质释放P物质,引发疼痛感受,直接驱动动物采取逃避、舔舐伤口等保护行为。其二,情绪系统的效价编码即基本情绪系统天然具备评估刺激生命价值的能力。恐惧系统将陌生环境、捕食者气味等编码为焦虑、痛苦等负性情绪,驱使动物通过僵直、逃跑等行为规避威胁;嬉戏系统则将同伴互动等编码为愉悦、兴奋等正性情感,促进动物发展社交能力,包括学习合作与建立

① 参见[美]潘克赛普、[英]彼文:《心智考古学:人类情绪的神经演化起源》,第32-43页。

② 同上,第96-144页。

③ 同上,第282-310页。

④ 达马西奥认为这种“现象学转译”是自发的:“内稳态感受的激进新颖性和力量(以及它们提供的信息使生物能够智能地做出反应并促进其生命的延续的原因)来自于‘内稳态感受是自发的(spontaneously)有意识的’这一事实。”(Antonio Damasio & Hanna Damasio, “Homeostatic Feelings and the Emergence of Consciousness”, *Journal of Cognitive Neuroscience* 36 (8), 2024, pp. 1653-1659.)

等级秩序。

更进一步,这类感受具有明确的主观性。条件性位置偏好实验(CPP)和条件性位置厌恶实验(CPA)表明,动物在体验到情绪系统激活带来的感受(如探索系统的愉悦感、恐惧系统的痛苦感)后,会通过条件反射主动趋近或回避曾引发该感受的环境。这种主动选择证明,动物存在对情绪感受的主观觉知,而该觉知是构成意识的最初形式:它无需复杂的认知反思,却能构建生物体原初的自我感——一种“我正处于痛苦或愉悦之中”的生命状态觉知。这是“以生命为核心”理论强调的“意识与自我感同延(coextension)”的底层逻辑。

三、机器不可能有意识以及人工意识的可能性

鉴于前文对“以生命为核心”的意识理论的简要阐述,我们得以立足生命本质,重新审视“机器是否可能具有意识”这一根本性问题。意识并非独立于生命体的抽象功能属性,而是生物体为维持内稳态演化出的具身感受(embodied feeling)。这一理解不仅挑战了传统计算功能主义视意识为“信息处理副产品”的假设,而且对机器意识的可能性提出深刻质疑。接下来,本文将基于“以生命为核心”的意识理论的立场,借助罗伯特·罗森的“生命-复杂系统”理论,论证为何在传统机器(尤其是基于图灵机模型的计算系统)中实现意识是不可能的。

(一)机器意识与人工意识

在探讨“机器是否可能具有意识”这一议题前,须首先厘清一对常被混淆但存在显著差异的概念——机器意识与人工意识。尽管它们均指向“人工构造有意识系统”的愿景,但在研究范围、理论前提与技术路径上存在本质差异。

机器意识通常指在机器系统(尤其是基于图灵机模型的传统计算架构)中实现意识的研究方向。其核心问题涉及两个方面:机器是否原则上能够拥有意识,即意识是否可以被还原为计算过程,并在非生命物理体系中实现?若此原则可行,如何通过工程手段(如算法设计、硬件模拟)使机器系统真正具备意识体验?此类研究常隐含假设:意识作为高阶功能属性,会随信息加工复杂度提升而“涌现”主观体验。该假设深受计算功能主义影响,试图将意识纳入“认知可计算”框架解决。

相较之下,人工意识的研究领域更为广阔。它不预设意识的载体必须是机器,而是深入探讨能否通过人工手段构建具备意识的物质系统。其基础性问题同样涵盖两个层面:原则上是否可通过人工方法(如合成生物学、仿生工程、人工生命设计)创造拥有意识体验的系统?若可行,当采取何种实现途径?

因此,机器意识与人工意识的核心分野在于:前者专注探讨“机器”载体能否实现意识,后者则着眼于“人工构造意识系统”的广义可行性;前者致力于在非生命计算框架中模拟意识,后者则可能通过仿生或合成生命方法,在具有生命特征的系统基础上实现意识。

从“以生命为核心”的意识理论立场看,此分野至关重要。正如潘克赛普和达马西奥所论证的,意识作为生命体维持内稳态的具身现象,其形成和实现必然与生命的组织原则和动力学特性紧密相关。传统图灵机缺乏生命的组织形式和目的性,使机器意识面临原则性障碍;而人工意识通过构建具有生命特征的人工系统,可能成为可行路径。

(二)基于罗森理论的论证要点

罗伯特·罗森在《预期系统》《生命本身》《论生命本身论文集》^①等著作中,构建了一套关于生命的“复杂系统”理论,对生物学中居于主导地位的还原论范式提出了根本性质疑。罗森理论的核心创见在于,他通过数学与范畴论工具,严格区分了简单/繁杂系统(simple/complicated system)与复杂系统(complex system)。前

^① See Robert Rosen, *Anticipatory Systems: Philosophical, Mathematical, and Methodological Foundations* (2nd ed.), New York: Springer, 2012 (Original work published 1985); Robert Rosen, *Life Itself: A Comprehensive Inquiry into the Nature, Origin, and Fabrication of Life*, New York: Columbia University Press, 1991; Robert Rosen, *Essays on Life Itself*, New York: Columbia University Press, 2000.

者(如所有传统机器)虽可包含海量部件,但其因果结构本质上是可分解的;而生命系统作为后者,其内在的(M, R)系统组织形式蕴含了一个不可还原的因果闭环,即代谢与修复功能互为因果、自我指涉。罗森证明,具有此类组织形式的系统在范畴上不同于图灵机,因而在原理上无法被任何计算模型完全模拟。

基于此理论框架,本节将论证:生命作为一种具有内在因果闭环的复杂系统,是图灵不可计算的。意识是根植于生命这种特定的、自我维持的复杂因果结构之上而演化出的属性和功能。因此,任何基于图灵机范式的计算系统(包括所有当代人工智能),由于其本质仍属于简单/繁杂系统范畴,在原理上无法实现必须基于生命的意识。

其一,简单/繁杂系统与复杂系统

罗森对生命本质的探索始于对“系统复杂性”概念的颠覆性重塑。这一理论突破不仅划清了“复杂”与“简单/繁杂”的本质界限,而且成为论证“生命不可被图灵机模拟”的理论基石。传统科学长期将系统复杂性等同于组分数量的多寡,误将“繁杂”(如由大量简单部件构成的机械)视作“复杂”,却忽视了系统行为的核心驱动力并非组分本身,而是组分间因果关系的组织形式。罗森指出,真正的复杂性根植于不可还原的因果结构。这一洞见不仅区分了简单/繁杂系统与复杂系统,而且从根本上揭示了生命与机器的本质差异,为理解生命的不可计算性提供了理论框架。

罗森将简单/繁杂系统定义为具有可形式化、可计算模型的系统:“为便于后续论述,我将满足以下条件的自然系统(natural system)N定义为‘机制’(mechanism):(1)它具有一个最大模型,该模型由状态集合及一个从当前状态推导后续状态的递归规则构成;(2)其所有其他模型均可通过形式化方法从该最大模型派生。据此,我所阐述的‘自然法则’(natural law)的新表述可归结为这样一个论断:所有自然系统皆为机制。我们将在后续讨论机器(特别是第八章及之后章节)时重新审视这一论断。”^①简单/繁杂系统的核心特征是因果关系的线性化与可拆解性,这使得还原论方法成为分析此类系统的有效工具,即只需将系统拆解为独立子系统,通过分析子系统的行为即可叠加得出整体功能。图灵机、钟表、计算机等传统人造机器,均属于这一范畴。

从因果结构看,简单/繁杂系统的因果链呈单向线性,不存在不可还原的闭环。以图灵机为例,其运行完全依赖预设的句法规则:输入符号经固定算法处理后输出结果,整个过程中不存在子系统间“相互生成、相互调控”的循环——算法是外部预设的,符号仅作为句法载体而无自主语义,输入与输出的关系具有确定性。传统机械(如钟表)的因果关系更为直观:齿轮的转动依赖前一齿轮的动力传递,每个部件的作用都是单向的动力输出-接收,不存在“部件自主调控整体”的闭环,一旦拆解为齿轮、发条等孤立部件,其机械功能的逻辑链条仍可完整还原。

从模型特性看,这类系统的行为可被“纯句法”完全描述。所谓“句法”即仅关注部件的物理属性与形式规则,不涉及功能层面的“语义”。图灵机的本质是符号的句法操作:无论输入符号代表何种意义(如数字、文字),其处理过程仅遵循符号的形式逻辑,与语义无关;钟表的运行依赖齿轮的尺寸、齿数等物理参数,无需处理“计时”这一功能本身的自主性意义。这意味着,简单或繁杂系统的行为可被有限算法完全捕获,即只要预设足够精细的规则,便可通过图灵机模拟其所有可能行为,不存在不可预测的“语义涌现”。

与简单/繁杂系统相对,罗森将复杂系统定义为具有不可形式化、非计算性模型的系统:“在这一过程中,我们会(除其他特征外)创造出具有动力因闭环(closed loops of efficient causation)的结构。此类系统无法通过有限状态机(如图灵机)进行模拟,因此它们本身不属于机器或机制的范畴。从形式层面看,这类系统呈现出非直谓循环(impredicative loops)的特性。我将其称为‘复杂系统’;其显著特征之一在于它们不存在最大的可模拟模型。”^②复杂系统的核心标志是不可还原的因果闭环。这种闭环并非简单的循环因果,而是亚

^① Robert Rosen, *Life Itself: A Comprehensive Inquiry into the Nature, Origin, and Fabrication of Life*, p.103.

里士多德“四因”(质料因、形式因、动力因、目的因)^①的全面交互,最终形成自组织、自维持的自主系统,而生命系统(从细胞到有机体)正是这类系统的典型代表。

其二,(M, R)系统

罗森提出的一个根本问题是:生命系统与机器最本质的区别在哪里?他的答案不是某种“生命力”,而是系统具有一种特定的组织形式。(M, R)系统就是他为了捕捉这种组织形式而构建的抽象模型。(M, R)系统代表“代谢-修复系统”,描述了一个系统必须具备哪些功能性组件以及它们之间必须存在怎样的关系,才能被视为“活的”。一个最基本的(M, R)系统包含三个核心功能组件:

一是代谢(Metabolism, M)。其功能是将外部输入(原料 A)转化为系统所需的产物(B)和能量。这就像细胞中的酶促反应网络,将食物转化为蛋白质、ATP 等。形式化为 $M: A \rightarrow B$ (一个将 A 映射为 B 的过程)

二是修复(Repair, R)。其功能是识别并替换代谢过程中因损耗而失效的组件。最关键的是, R 修复的对象是代谢功能 M 本身(如替换掉失活的酶)。细胞内的核糖体根据 mRNA 的指令合成新的酶,这一过程类似于细胞代谢活动中的蛋白质合成机制。形式化为 $R: B \rightarrow M$ (一个利用代谢产物 B 来重建代谢功能 M 的过程)

三是复制(Replication, β)。这是解决“无穷倒退”问题的关键。如果 R 也会损耗,谁来修复 R? 复制的功能是利用代谢功能 M 的输出,来合成和维持修复功能 R 本身。这里的关键在于, β 不是一个独立的组件,而是系统组织关系中固有的一个映射,它代表了 M 具有产生 R 的“能力”。形式化为 $\beta: M \rightarrow R$ (一个从 M 到 R 的映射关系)

(M, R)系统的精髓在于这些组件之间形成了一个不可分解的因果闭环,罗森称之为“动力因闭合”(closed to efficient causation)。这个系统最深刻的地方在于,它没有需要外部提供的“最终指令”,它的所有功能(M, R)的存在和维持都被系统内部其他功能的活动所蕴含。这就切断了无穷倒退的链条。(M, R)系统蕴含的关键推论和意义在于:一是它是自我生产的(self-producing)或自创生的(autopoietic),它用自己的产物不断地重建自身,这是生命最根本的特征;二是它是不可还原的,其因果闭环不可分解,即如果移走 R 则 M 会崩溃,如果移走 M 则 R 也无法存在,可见系统的“生命”属性存在于整个关系网络中,而不是任何一个孤立的部件里;三是它是不可计算的,罗森用范畴论证明这种具有闭合因果环的组织模式在范畴上不同于图灵机,这意味着不可能为这样一个系统建立一个完整的、可预测的“最简模型”,任何试图这样做的计算机模拟都会丢失其最本质的“生命”属性。

细胞的生命活动更直观地体现了这种因果闭环的复杂性。DNA 作为形式因,通过碱基序列储存遗传信息,指导蛋白质合成;蛋白质作为质料因,既是细胞结构的组成部分,又以酶的形式作为动力因调控 DNA 的转录与表达(如某些酶可激活或抑制特定基因);而这一系列过程的最终指向是细胞的存活、繁殖和适应环境(目的因)。在这一闭环中,每个环节既是原因也是结果:DNA 指导蛋白质合成,蛋白质又调控 DNA 活性,不存在可独立拆解的线性因果链。若将 DNA 从细胞中分离,它便只是一段携带碱基序列的化学分子,失去“指导生命活动”的功能;若移除蛋白质, DNA 的遗传信息也无法转化为实际生命行为,只有在因果闭环的整体中,各组分才具有生命意义。

其三,生命不同于机器,是图灵机不可计算的

传统将生命类比为“精密机器”的观点(如笛卡尔的“动物自动机”说),在罗森的理论框架下彻底失

① 在生命研究中,罗森吸收和复活了亚里士多德的“四因说”(特别是目的因),但也有扬弃。“我们类比了他的四个因果类别中的三个;具体来说,如果我们称定理 P 为一个结果,我们可以将他的质料因概念与形式系统的公理等同,动力因概念与其生产规则等同,形式因概念与特定序列或生产规则算法的规范等同,从而生成从公理到 P 的命题轨迹……科学中对目的性的拒绝通常是在这种时间背景下提出的,以一条渗透所有理论科学的未明言的‘零’诫命的形式:‘汝不可让未来影响现在。’”“实际上,我基于形式理由建议,有可能将目的性(finality)与目的论(teleology)分离开,保留前者而丢弃后者……将目的性以它所需的额外蕴含模式纳入我们的框架,不仅是可能的,而且是关键的。”(Robert Rosen, *Life Itself: A Comprehensive Inquiry into the Nature, Origin, and Fabrication of Life*, p.49.)

效——生命与机器分属复杂系统与简单系统,二者的差异源于“因果闭环的有无”,具体体现在自主性与可还原性两个维度。从自主性看,机器的存在完全依赖外部预设的目标与规则。计算机的运算需要程序员输入程序(外部目标),汽车的行驶需要驾驶员设定路线(外部指令),其部件的互动仅是“被动执行预设规则”,不存在自我设定目标的因果闭环——若失去外部输入,机器便会停止运行。相反,生命系统通过代谢、修复、复制等过程,能自主维持自身存在:细胞会根据环境变化调整基因表达(如缺氧时激活缺氧诱导因子),有机体可通过免疫系统抵御病原体,这种自主性是因果闭环的内在涌现属性,无需外部赋予。从可还原性看,还原论是分析机器的有效方法,但对生命系统完全失效。机器的功能可完全还原为部件的属性:计算机的运算功能可还原为晶体管的开关状态,汽车的动力功能可还原为发动机气缸的燃烧与活塞的运动,即便拆解为孤立部件,仍能通过“部件属性叠加”还原整体属性。而生命系统的属性依赖于因果闭环的整体性,无法被还原为孤立部件,例如将细胞拆解为DNA、蛋白质和细胞膜后,每个部件都失去了原有的生命功能(如DNA无法自主复制、蛋白质无法调控代谢)。罗森指出,生命系统的整体属性不是组件属性的叠加,而是因果闭环产生的“涌现属性”(emergent property),这种属性仅存在于系统整体中,一旦拆解便会消失。

生命系统这种自我指涉(或闭环)的因果结构,决定了生命系统具有本质上的“不可计算性”:任何试图用有限算法(如图灵机程序)模拟生命的努力,都会陷入“无穷递归”的困境,而这与图灵机的“有限性本质”根本矛盾。罗森从数学上证明,具有(M, R)结构的系统,其因果蕴含关系无法被任何单一、有限的形式系统完全捕获:若要模拟代谢对修复的依赖,就需要先定义修复的规则;而定义修复规则,又需回溯至代谢提供的资源条件;这种“定义A需依赖B,定义B又需依赖A”的自我指涉,会导致模拟过程无限递归,无法收敛为有限步骤的算法。

更关键的是,不可计算性并非技术局限(如算力不足),而是根植于生命系统的“语义自主性”(semantic autonomy)——系统的行为不仅依赖组件的物理属性(句法),更依赖组件间的功能性关联(语义),且这种语义无法脱离因果闭环的整体语境而存在。正如罗森所言:“哥德尔的结论终结了这一计划。简言之,这些结论意味着一个由纯句法构成的、有限生成的可构造宇宙过于贫瘠,无法进行数学研究。它们意味着语义、非直谓性(impredicativities)和意义对数学至关重要;它们不能被更多的句法规则、列表或算法所取代……我认为生物学告诉我们,物质世界也是如此……生物体是意义和非谓性的储存库;它比无机系统更一般,而非更特殊。”^①例如,DNA的碱基序列是句法符号(物理属性),但只有在细胞的因果闭环中,它才具有“指导蛋白质合成、调控细胞活动”的语义;一旦脱离闭环,DNA的语义便消失,只剩下化学分子的物理特性。罗森强调,这种“语义-句法的不可分离性”使复杂系统的模型无法被还原为纯句法的计算规则;而图灵机的本质恰是句法操作的自动化,它只能处理预设的形式规则,无法自主生成或理解依赖整体语境的语义,自然无法模拟生命系统的自主性行为。图灵机对生命系统的模拟本质上是用“简单系统的逻辑”适配“复杂系统的组织”,因此,必然面临根本性局限。

其四,意识同样是图灵机不可计算的

“以生命为核心”的意识理论深刻揭示了意识不仅是生命现象,更是生物体调节内稳态的高级形式;罗森的“生命-复杂系统”理论则强有力地证明了生命并非机器,是图灵机无法模拟的。基于这两种理论,我们可以得出明确的结论:意识同样不可被图灵机模拟,机器意识乃至AI意识都不可能实现。

(三)基于人工内稳态的人工意识的可能性

若我们接受“以生命为核心”的意识理论,即意识在本质上是为生命存续与适应服务的内稳态调节机制,那么实现人工意识的路径必然指向生命系统的仿生建构,而非传统计算范式的延续。这暗示着我们应超越以算法和符号处理为核心的机器意识研究,转而探索如何构建具备自主内稳态调节能力的人工内稳态系统(artificial homeostatic system),并在此基础上孕育真正的主观体验。

^① Robert Rosen, *Essays on Life Itself*, pp. 3-4.

此类系统的设计需遵循四个核心原则:一是具身性(embodiment),即系统必须拥有能与环境持续交换物质、能量与信息的“身体”,从而为内稳态提供真实的调节对象与信号源;^①二是须具备多层级的反馈和闭环调节机制,能实时监测内部状态(如能量水平、结构完整性)及外部环境,并作出适应性响应;三是形成将内稳态偏差转化为具正负效价的“感受”信号,以驱动系统趋利避害;四是须具备自我建模与预期能力,使系统可基于历史经验优化行为策略,形成初步的“自我-环境”区分。

在技术路径层面,实现此类人工系统可能依托仿生机器人学、合成生物学或生命-机器混合系统等领域的发展。例如,借合成生物学技术构建具代谢、修复与自我复制能力的人工细胞,或开发能自主维持能量平衡与结构完整的仿生机器人,甚至设计融合生物组织与电子元件的混合内稳态架构。这些路径共同指向一个根本目标:在非天然的物质载体上重演生命的组织形式与动力学特征,从而为意识的涌现奠定基础。值得注意的是,这种进路不仅挑战了传统的强人工智能愿景,更引发了深刻的伦理问题:一旦成功构建出具有感受能力的人工系统,我们是否已准备好承担相应的道德责任?因此,未来人工意识的研究必须在科学与伦理的双重框架下协同演进。^②

四、结 语

本文基于“以生命为核心”的意识理论,简明地阐述了意识作为生命体维持内稳态的高级调节机制的本质特征。“生命转向”的意识研究表明,意识起源于皮层下的情绪系统,其核心在于生物体上自然发生的内稳态参数的神经映射向主观感受的转译。这种具身感受不仅构成意识和自我感的原初形态,更因其内在的情感效价而成为生物体适应性行为的驱动力。“以生命为核心”的意识理论彻底解构了计算功能主义将意识视为抽象信息加工副产物的传统范式。通过辨析机器意识与人工意识的差异,并融合罗森的生命系统理论,本文进一步论证:生命系统的因果闭环属性使其无法被图灵机模拟,而意识作为生命的核心表征,自然难以在传统计算架构中实现。因此,机器意识与AI意识在原则上不具备可能性。

然而,这并非否定人工意识的潜力。若能超越计算范式,以生命原理为基石,构建具备自主内稳态调节能力的人工生命系统,意识的涌现便具备理论上的可能。这一路径不仅呼应了意识的生物学本质,也为人工意识研究锚定了方向。未来的探索需在生命原理解析、仿生系统构建与伦理规范确立的三重维度上协同推进。唯有在科学与人文的双重引导下,人工意识的探索才能稳步迈向具有生命真实感的意识建构之路。必须强调的是,意识研究的“生命转向”不仅是对强人工智能梦想的修正,更是对人类理解自身本质的深化。它提醒我们,意识的本质在于因生命内稳态调节而自发转译的主观体验、自我感和情感驱动力。因此,人工意识的研究不应止步于功能的复制,更须珍视并深入理解意识的生命本质。

【责任编辑 诚 之】

① 汤普森(Evan Thompson)有力地反驳了传统的计算主义。他发展了“生成”进路,指出认知和意识根植于生命体的自主、自组织和自我保存的动态过程(自创生);具身性、自组织以及生命与心智之间的根本联系是其思想的核心。(参见[加]汤普森:《生命中的心智:生物学、现象学和心智科学》,李恒威、李恒熙等译,杭州:浙江大学出版社,2013年。)

② See Steve Torrance, “Artificial Agents and the Expanding Ethical Circle”, *AI & Society* 28 (4), 2013, pp. 399–414.